

# Random Features for large scale kernels (Caracterización aleatoria para kernels a gran escala)

- Sea  $x \in \mathcal{X}$  y  $\phi: \mathcal{X} \rightarrow \mathcal{H}$  una función de mapeo al espacio de Hilbert  $\mathcal{H}$ , tal que el producto interno:  $K(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}$ , con kernel  $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}^+$ , como función definida positiva.
- Sea  $\{x_n \in \mathcal{X} \subset \mathbb{R}^p\}_{n=1}^N$ , se estima la matriz  $K \in \mathbb{R}^{N \times N}$ .
- Para problemas a gran escala  $N \rightarrow \infty$ .
- $\mathcal{H} \subset \mathbb{R}^Q$ ;  $Q \rightarrow \infty$ .
- **Propuesta**: Encontrar espacio de menor dimensión;  $\mathcal{H} \subset \mathbb{R}^q$ ;  $q < Q$ ; desde el mapeo aleatorizado  $z: \mathbb{R}^p \rightarrow \mathbb{R}^q$ , tal que:  
$$K(x, x') = \langle \phi(x), \phi(x') \rangle \simeq \langle z(x), z(x') \rangle$$

## Aproximación de Kernel estacionarias (invariantes al desplazamiento)

- Propiedad reproductiva:



$$f(x) = \sum_{i=1}^N \alpha_i k(x_i, x)$$

- Mediante aproximación autorizada:

$$f(x) = \langle w, z(x) \rangle = w^T z(x)$$

## Características de Fourier autorizadas.

-  $\cos(w^T x + b)$ ,  $w \in \mathbb{R}^d$ ,  $b \in \mathbb{R}$ .



## Teorema Bochner.

$$k(x, x') = k(x - x')$$

es definida positiva si y solo si  $k(\delta)$  es la transformada de Fourier de una medida no-negativa.

- Si un Kernel estacionario  $k(\delta)$  es escalado, Bochner garantiza que su transformada  $p(\omega)$  es una función distribución.

- Sea  $f_\omega(x) = e^{j\omega^T x}$ :

$$k(x-x') = F^{-1}\{p(\omega) | e^{j\omega^T(x-x')}\} = \frac{1}{2\pi} \int p(\omega) e^{j\omega^T(x-x')} d\omega$$

$$k(x-x') = \frac{1}{2\pi} E_{p(\omega)} \{e^{j\omega^T x} e^{-j\omega^T x'}\} \propto E_{p(\omega)} \{f_\omega(x) f_\omega^*(x')\}$$

- Dado  $k(x-x'), p(\omega) \in \mathbb{R}$ :

$$k(x-x') = \int p(\omega) [\cos(\omega^T(x-x')) + j \sin(\omega^T(x-x'))] d\omega$$

$$k(x-x') = \int p(\omega) \cos(\omega^T(x-x')) d\omega + j \int p(\omega) \sin(\omega^T(x-x')) d\omega$$

$$k(x-x') = \text{Re}\{k(x-x')\} + j \text{Im}\{k(x-x')\}$$

Por ende se puede trabajar solo con  
Cosenos.

$$\rightarrow z_w(x) = \sqrt{2} \cos(w^T x + b); \quad w \sim p(w)$$

$$b \sim u(b | 0, 2\pi)$$

$$\hat{k}(x-x') = \mathbb{E}_w [z_w(x) z_w(x')]$$

→ Para mejorar la varianza del estimador:

$$\{z_{w_j}(x)\}_{j=1}^q = \mathbb{Z}(x)$$

$$K(x-x') = \langle \mathbb{Z}(x), \mathbb{Z}(x') \rangle = \frac{1}{q} \sum_{j=1}^q z_{w_j}(x) z_{w_j}(x')$$

**Algoritmo:** Capa Kernel → Random Fourier

1. Entrada:  $k(x, x') = k(x-x') \rightarrow$  kernel estacionario
2. Salida:  $\mathbb{Z}: \mathbb{R}^p \rightarrow \mathbb{R}^q$ ;  $\langle \mathbb{Z}(x), \mathbb{Z}(x') \rangle \approx k(x-x')$
3. Calcular  $p(w) = \frac{1}{2\pi} \int k(\delta) e^{-j\omega^T x} \delta \delta = \frac{1}{2\pi} \mathcal{F}\{k(\delta)\}$

$$w \sim p(w); \quad b \sim u(b | 0, 2\pi)$$

$$4. \mathbb{Z}(x) = \sqrt{\frac{2}{q}} [\cos(w_1^T x + b_1), \dots, \cos(w_q^T x + b_q)]$$

5. Crear capa según  $\mathbb{Z}$  y entrenar por backpropagation.

## Algunos casos de interés:

Kernel Gaussiano:  $k(\Delta) = e^{-\frac{\|\Delta\|_2^2}{2\sigma^2}}$

$$p(w) = (2\pi)^{-\frac{p}{2}} e^{-\frac{\|w\|_2^2}{2\sigma^2}}$$

Kernel Laplaciano:  $k(\Delta) = e^{-\|\Delta\|_1}$

$$p(w) = \prod_j \frac{1}{\pi(1+w_j^2)}$$

Cauchy

$$k(\Delta) = \prod_j \frac{2}{1+\Delta_j^2}$$

$$p(w) = e^{-\|w\|_1}$$

